

ESTATÍSTICA MULTIVARIADA APLICADA À ZOOTECNIA DE NÃO RUMINANTES:

Fundamentos, Métodos e Aplicações em Ciência de
Dados

Tatiane Carvalho Alvarenga

Sumário

1	Introdução	3
2	Introdução à Estatística Multivariada	3
2.1	Conceitos, vetores, matrizes, tipos de variância e particionamento . . .	3
2.2	Ortogonalidade e Teorema da Decomposição Espectral	5
2.3	Maximização de Formas Quadráticas	5
3	Distribuição Normal Multivariada e Inferências sobre Médias Multi- variadas	5
3.1	Conceitos, procedimentos práticos e gráficos Q-Q	5
3.2	Detecção de outliers e transformações de variáveis	6
3.3	Lambda de Wilks, Traço de Pillai e Lawley-Hotelling	6
4	Análise de Componentes Principais (ACP)	7
4.1	Objetivos e álgebra geral	7
4.2	Padronização e interpretação	7
4.3	Teste de Bartlett	7
5	Análise Fatorial (AF)	8
5.1	Objetivos e álgebra geral	8
5.2	Métodos de estimação das cargas fatoriais	8
5.3	Rotação dos fatores	8

5.4	Escores fatoriais e validação	8
5.5	Critérios KMO e Bartlett	9
6	Análise de Correlação Canônica (ACC)	9
6.1	Objetivos e álgebra geral	9
6.2	Interpretação e qualidade do ajuste	9
6.3	Inferências e aplicações práticas	9
7	Análise de Cluster	10
7.1	Objetivos e álgebra geral	10
7.2	Medidas de similaridade e dissimilaridade	10
7.3	Técnicas hierárquicas e não hierárquicas	10
7.4	Critérios para partição final	11
8	Abordagens Alternativas	11
8.1	Escalonamento Multidimensional (MDS)	11
8.2	Análise Comparativa Qualitativa (fsQCA)	11
9	Análise Discriminante	11
9.1	Objetivos e álgebra geral	11
9.2	Regras linear e quadrática	11
9.3	Qualidade do ajuste	12
9.4	Classificação com várias populações	12
9.5	Seleção de variáveis	12
10	Análise de Correspondência	12
11	Considerações Finais	12
12	Referências Bibliográficas	13

1 Introdução

A Estatística Multivariada representa um dos pilares metodológicos mais importantes da Ciência de Dados moderna, especialmente em áreas aplicadas que lidam com fenômenos complexos, multidimensionais e altamente correlacionados, como a zootecnia de não ruminantes. Em sistemas de produção animal envolvendo aves, suínos, peixes e outras espécies monogástricas, o pesquisador frequentemente trabalha com dezenas ou centenas de variáveis simultaneamente: ganho de peso, conversão alimentar, composição corporal, parâmetros fisiológicos, dados genômicos, comportamento animal, variáveis ambientais, qualidade da carne, microbiota intestinal e indicadores econômicos.

Nesse contexto, métodos univariados tradicionais tornam-se insuficientes, pois ignoram a estrutura de dependência entre variáveis. A estatística multivariada surge exatamente para modelar relações simultâneas entre múltiplas características, permitindo reduzir dimensionalidade, identificar padrões ocultos, classificar indivíduos, detectar agrupamentos, construir índices biológicos e realizar inferências robustas.

Na zootecnia contemporânea, especialmente diante da Agricultura 4.0 e da pecuária de precisão, a integração entre Estatística Multivariada e Ciência de Dados tornou-se estratégica. Sensores, inteligência artificial, visão computacional, fenotipagem de alta precisão e genômica produzem grandes volumes de dados, exigindo técnicas matemáticas sofisticadas para extração de conhecimento.

Assim, dominar Estatística Multivariada não significa apenas conhecer algoritmos, mas compreender profundamente a geometria dos dados, a álgebra matricial subjacente, os fundamentos probabilísticos e a interpretação biológica dos resultados.

2 Introdução à Estatística Multivariada

2.1 Conceitos, vetores, matrizes, tipos de variância e particionamento

A Estatística Multivariada baseia-se na análise simultânea de várias variáveis aleatórias. Seja um vetor aleatório:

$$\mathbf{X} = (X_1, X_2, \dots, X_p)^T \quad (1)$$

em que p representa o número de variáveis observadas.

Na produção de frangos de corte, por exemplo, um vetor multivariado pode conter:

- consumo de ração;
- ganho de peso;
- conversão alimentar;
- rendimento de peito;
- mortalidade;
- temperatura corporal;
- concentração sérica de glicose.

Os dados multivariados são organizados em matrizes. Considerando n animais e p variáveis:

$$\mathbf{X}_{n \times p} \quad (2)$$

Cada linha representa um indivíduo e cada coluna uma variável.

A variabilidade multivariada é descrita pela matriz de covariâncias:

$$\mathbf{\Sigma} = \begin{bmatrix} \sigma_{11} & \sigma_{12} & \cdots & \sigma_{1p} \\ \sigma_{21} & \sigma_{22} & \cdots & \sigma_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{p1} & \sigma_{p2} & \cdots & \sigma_{pp} \end{bmatrix} \quad (3)$$

Os elementos diagonais representam variâncias e os fora da diagonal representam covariâncias.

Na zootecnia, o particionamento da variância possui enorme relevância prática. Em programas de melhoramento genético de suínos, por exemplo, a variância fenotípica pode ser decomposta em:

- variância genética;
- variância ambiental;
- interação genótipo $\times$ ambiente.

Essa decomposição permite compreender quais fatores influenciam desempenho produtivo e eficiência alimentar.

2.2 Ortogonalidade e Teorema da Decomposição Espectral

A ortogonalidade representa independência geométrica entre vetores. Dois vetores são ortogonais quando:

$$\mathbf{x}^T \mathbf{y} = 0 \quad (4)$$

Na Análise de Componentes Principais (ACP), os componentes são construídos ortogonalmente para evitar redundância de informação.

O Teorema da Decomposição Espectral afirma que qualquer matriz simétrica pode ser decomposta em:

$$\mathbf{A} = \mathbf{P} \mathbf{D} \mathbf{P}^{-1} \quad (5)$$

em que:

- P contém os autovetores;
- D contém os autovalores.

Esse resultado é central na ACP e na análise fatorial.

2.3 Maximização de Formas Quadráticas

Grande parte da Estatística Multivariada envolve problemas de otimização. Uma forma quadrática geral é:

$$Q = \mathbf{x}^T \mathbf{A} \mathbf{x} \quad (6)$$

Na ACP, busca-se encontrar combinações lineares das variáveis que maximizem a variância explicada.

3 Distribuição Normal Multivariada e Inferências sobre Médias Multivariadas

3.1 Conceitos, procedimentos práticos e gráficos Q-Q

A distribuição normal multivariada generaliza a distribuição normal univariada:

$$\mathbf{X} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma}) \quad (7)$$

A normalidade multivariada é pressuposto fundamental em diversos métodos:

- MANOVA;
- análise discriminante;
- correlação canônica;
- inferências multivariadas.

Os gráficos Q-Q multivariados com distância de Mahalanobis são amplamente utilizados.

A distância de Mahalanobis é definida como:

$$D^2 = (\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) \quad (8)$$

3.2 Detecção de outliers e transformações de variáveis

Outliers multivariados podem indicar:

- erros experimentais;
- falhas de sensores;
- doenças;
- animais metabolicamente distintos.

Transformações frequentemente utilizadas:

- logaritmo;
- Box-Cox;
- raiz quadrada.

3.3 Lambda de Wilks, Traço de Pillai e Lawley-Hotelling

A estatística Lambda de Wilks é definida como:

$$\Lambda = \frac{|\mathbf{E}|}{|\mathbf{E} + \mathbf{H}|} \quad (9)$$

Valores pequenos indicam diferenças significativas entre grupos.

O Traço de Pillai é robusto diante de violações de pressupostos.

O Traço de Lawley-Hotelling baseia-se nos autovalores canônicos.

O intervalo de Bonferroni é utilizado para controlar erro tipo I em inferências múltiplas.

4 Análise de Componentes Principais (ACP)

4.1 Objetivos e álgebra geral

A ACP é uma técnica de redução de dimensionalidade. Seu objetivo é transformar variáveis correlacionadas em componentes ortogonais:

$$Y_i = a_{i1}X_1 + a_{i2}X_2 + \cdots + a_{ip}X_p \quad (10)$$

Na avicultura moderna, sensores ambientais coletam múltiplas variáveis simultaneamente:

- temperatura;
- umidade;
- amônia;
- luminosidade;
- velocidade do vento.

A ACP permite sintetizar essas informações em poucos índices ambientais.

4.2 Padronização e interpretação

Quando variáveis possuem escalas diferentes, utiliza-se a matriz de correlação. A padronização ocorre por:

$$Z = \frac{X - \mu}{\sigma} \quad (11)$$

CrITÉRIOS importantes:

- autovalores maiores que 1;
- gráfico Scree Plot;
- variância acumulada.

4.3 Teste de Bartlett

O teste de esfericidade de Bartlett avalia se a matriz de correlação difere significativamente da matriz identidade.

5 Análise Fatorial (AF)

5.1 Objetivos e álgebra geral

A análise fatorial busca identificar fatores latentes responsáveis pelas correlações observadas.

$$X_i = \mu_i + l_{i1}F_1 + l_{i2}F_2 + \cdots + l_{im}F_m + \varepsilon_i \quad (12)$$

Na produção de suínos, diversas variáveis podem refletir fatores ocultos como eficiência metabólica, imunocompetência e qualidade ambiental.

5.2 Métodos de estimação das cargas fatoriais

Os principais métodos incluem:

- componentes principais;
- máxima verossimilhança;
- fatores principais.

5.3 Rotação dos fatores

A rotação melhora a interpretabilidade dos fatores.

Principais métodos:

- Varimax;
- Promax;
- Oblimin.

5.4 Escores fatoriais e validação

Os escores fatoriais representam posições individuais dos animais nos fatores latentes.

A validação envolve:

- comunalidades;
- resíduos;
- ajuste global.

5.5 Critérios KMO e Bartlett

O índice KMO mede adequação amostral:

- acima de 0,8: excelente;
- abaixo de 0,5: inadequado.

6 Análise de Correlação Canônica (ACC)

6.1 Objetivos e álgebra geral

A ACC investiga relações entre dois conjuntos de variáveis.

As variáveis canônicas são construídas como:

$$U = a_1X_1 + a_2X_2 + \cdots + a_pX_p \quad (13)$$

$$V = b_1Y_1 + b_2Y_2 + \cdots + b_qY_q \quad (14)$$

Busca-se maximizar:

$$\text{corr}(U, V) \quad (15)$$

6.2 Interpretação e qualidade do ajuste

A interpretação depende:

- das cargas canônicas;
- correlações estruturais;
- redundância.

6.3 Inferências e aplicações práticas

A significância geralmente é avaliada via Lambda de Wilks.

Na nutrição de aves, a ACC pode revelar quais perfis nutricionais se associam fortemente à qualidade da carcaça.

7 Análise de Cluster

7.1 Objetivos e álgebra geral

A análise de agrupamento busca identificar grupos homogêneos.

Na zootecnia, pode-se agrupar:

- linhagens genéticas;
- perfis metabólicos;
- padrões comportamentais;
- sistemas de produção.

7.2 Medidas de similaridade e dissimilaridade

A distância Euclidiana é dada por:

$$d(x, y) = \sqrt{\sum_{i=1}^p (x_i - y_i)^2} \quad (16)$$

Outras medidas incluem Manhattan e Mahalanobis.

7.3 Técnicas hierárquicas e não hierárquicas

Métodos hierárquicos:

- ligação simples;
- ligação completa;
- método de Ward.

O método K-means minimiza:

$$\sum_{i=1}^k \sum_{x \in C_i} ||x - \mu_i||^2 \quad (17)$$

7.4 Critérios para partição final

Critérios importantes:

- Silhouette;
- Gap Statistic;
- pseudo-F.

8 Abordagens Alternativas

8.1 Escalonamento Multidimensional (MDS)

O MDS representa objetos em espaço de baixa dimensão preservando distâncias.

Na zootecnia, pode ser utilizado para visualizar similaridade genética entre linhagens de frangos.

8.2 Análise Comparativa Qualitativa (fsQCA)

A fsQCA combina lógica booleana e teoria dos conjuntos fuzzy.

Na produção animal, pode identificar combinações de manejo, genética, ambiente e nutrição associadas à alta produtividade.

9 Análise Discriminante

9.1 Objetivos e álgebra geral

A análise discriminante busca classificar observações em grupos previamente conhecidos.

A função discriminante linear é:

$$D = a + b_1X_1 + b_2X_2 + \cdots + b_pX_p \quad (18)$$

9.2 Regras linear e quadrática

A análise discriminante linear assume matrizes de covariância iguais.

A análise discriminante quadrática permite covariâncias diferentes.

9.3 Qualidade do ajuste

Avalia-se:

- taxa de classificação correta;
- validação cruzada;
- matriz de confusão.

9.4 Classificação com várias populações

Na piscicultura, pode classificar espécies segundo perfis ambientais.

9.5 Seleção de variáveis

Métodos stepwise ajudam identificar variáveis mais discriminantes.

10 Análise de Correspondência

A análise de correspondência é aplicada a tabelas de contingência e permite visualizar relações entre categorias.

Na zootecnia, pode investigar associações entre:

- sistemas de manejo;
- categorias sanitárias;
- níveis de desempenho.

A técnica produz mapas perceptuais extremamente úteis para interpretação visual.

11 Considerações Finais

A Estatística Multivariada constitui ferramenta indispensável para a moderna Ciência de Dados aplicada à zootecnia de não ruminantes. O aumento exponencial da complexidade dos sistemas produtivos, associado ao avanço da fenotipagem de precisão, genômica, sensoriamento remoto e inteligência artificial, exige profissionais capazes de integrar matemática, estatística, computação e interpretação biológica.

Mais do que dominar softwares, o pesquisador contemporâneo precisa compreender os fundamentos algébricos, geométricos e probabilísticos que sustentam os métodos

multivariados. Essa base teórica permite interpretar corretamente os resultados, evitar inferências equivocadas e produzir conhecimento científico robusto.

A tendência futura aponta para integração crescente entre Estatística Multivariada clássica, aprendizado de máquina e inteligência artificial explicável. Métodos como ACP, análise fatorial, análise discriminante e clusterização continuam extremamente relevantes, servindo inclusive como fundamento conceitual para técnicas modernas de machine learning.

12 Referências Bibliográficas

Referências

- [1] ANDERSON, T. W. *An Introduction to Multivariate Statistical Analysis*. New York: Wiley.
- [2] HAIR, J. F. et al. *Multivariate Data Analysis*. Pearson.
- [3] JOHNSON, R. A.; WICHERN, D. W. *Applied Multivariate Statistical Analysis*. Pearson.
- [4] MANLY, B. J. F. *Métodos Estatísticos Multivariados*.
- [5] MINGOTI, S. A. *Análise de Dados Através de Métodos de Estatística Multivariada*.
- [6] RENCHER, A. C. *Methods of Multivariate Analysis*.